

ESTIMAÇÃO PARAMÉTRICA

Parte 2 - Estimação Pontual

Introdução

X : variável aleatória (v.a.) cuja distribuição de probabilidade depende de um **parâmetro desconhecido** θ , $\theta \in \Theta \subseteq \mathbb{R}^k$, que pretendemos estimar.

Por exemplo, muitas vezes conseguimos tecer conjeturas sobre a função de probabilidade de X , se X é discreta, ou sobre a função densidade de X , se X é contínua, mas na expressão dessa função há parâmetros desconhecidos que pretendemos estimar.

Ao conjunto Θ chamamos **espaço dos parâmetros** (por exemplo, na distribuição $N(m, \sigma)$ com m e σ desconhecidos, temos $\Theta = \mathbb{R} \times \mathbb{R}^+$).

Amostra aleatória

É natural que as inferências sobre a população em estudo dependam da amostra concreta observada, (x_1, \dots, x_n) . No entanto, os procedimentos estatísticos em que se baseiam tais conclusões não devem depender de uma amostra particular. Assim, para estudar tais procedimentos, não nos baseamos em amostras concretas mas sim em *amostras aleatórias*.

→ **Amostra aleatória** de X de dimensão n , $n \in \mathbb{N}$: vetor (X_1, \dots, X_n) constituído por variáveis aleatórias X_1, \dots, X_n independentes e que seguem a mesma distribuição de X (ou seja, X_1, \dots, X_n são i.i.d. com X).

Estimador e estimativa

A partir de agora consideramos $\Theta \subset \mathbb{R}$.

Estimador do parâmetro θ : é qualquer variável aleatória real T_n que seja função de X_1, \dots, X_n (mas não de θ) e que tome valores em Θ .

Seja $g : \Theta \longrightarrow \mathbb{R}$.

Estimador de $g(\theta)$: é qualquer variável aleatória real U_n que seja função de X_1, \dots, X_n (mas não de θ) e que tome valores no contradomínio de g .

Estimativa de θ (resp., $g(\theta)$): é um valor concreto de T_n (resp., U_n), sendo por isso calculado com base numa amostra observada de X . Usualmente, a notação usada para a estimativa é a mesma do estimador, mas com letra minúscula.

Por exemplo, sendo (X_1, \dots, X_{50}) uma amostra aleatória de uma v.a. X , cujo valor médio, $E(X)$, desconhecemos, um estimador de $E(X)$ é

$\bar{X}_{50} = \frac{1}{50} \sum_{i=1}^{50} X_i$. Para obter uma estimativa, temos que ter uma amostra concreta/observada de X .

Suponhamos que dispomos de uma amostra observada de X ,

(x_1, \dots, x_{50}) , tal que $\sum_{i=1}^{50} x_i = 376.8$. Então uma estimativa de $E(X)$ é

$$\bar{x}_{50} = \frac{376.8}{50} = 7.536.$$

Se considerarmos outra amostra observada de X de dimensão 50, ao mesmo estimador \bar{X}_{50} poderá corresponder uma estimativa de $E(X)$ diferente da anterior.

Estimadores e estimativas cêntricos e assintoticamente cêntricos

Seja X uma v.a. cuja distribuição de probabilidade depende de um parâmetro desconhecido θ , $\theta \in \Theta \subseteq \mathbb{R}$.

- Diz-se que T_n é um **estimador cêntrico** (ou **não enviesado**) de θ se $E(T_n) = \theta$, $\forall \theta \in \Theta$.
- Diz-se que T_n é um **estimador assintoticamente cêntrico** (ou **assintoticamente não enviesado**) de θ se $\lim_{n \rightarrow +\infty} E(T_n) = \theta$, $\forall \theta \in \Theta$.

Uma **estimativa cêntrica** (resp., **assintoticamente cêntrica**) de θ é um valor concreto de um estimador cêntrico (resp., assintoticamente cêntrico) de θ calculado com base numa amostra observada de X .

Estimação de $E(X)$ e $V(X)$

Consideremos uma v.a. X cuja distribuição de probabilidade depende de um parâmetro desconhecido θ , $\theta \in \Theta \subseteq \mathbb{R}$. Suponhamos que, independentemente do valor de θ , $E(X)$ e $V(X)$ existem mas são desconhecidas. Para simplificar a escrita, usamos as notações $m = E(X)$ e $\sigma^2 = V(X)$.

Seja (X_1, X_2, \dots, X_n) uma amostra aleatória de X (ou seja, X_1, X_2, \dots, X_n são v.a.'s independentes e todas com a mesma distribuição de X).

Estimação de m

→ Chamamos **média empírica** à v.a. $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$.

Propriedade 1. \bar{X}_n é um estimador cêntrico de m .

Demonstração. \bar{X}_n é um estimador cêntrico de m se e só se $E(\bar{X}_n) = m$. Ora, pela linearidade da esperança matemática, tem-se

$$E(\bar{X}_n) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} \sum_{i=1}^n m = \frac{1}{n} nm = m,$$

como se pretendia mostrar.

Dada uma amostra observada de X , (x_1, x_2, \dots, x_n) , podemos obter um valor concreto de \bar{X}_n : $\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$.

Como \bar{x}_n é uma concretização de um estimador cêntrico de $E(X)$, dizemos que \bar{x}_n é uma estimativa cêntrica de $E(X)$.

Propriedade 2. $V(\bar{X}_n) = \frac{\sigma^2}{n}.$

Demonstração. Tem-se $V(\bar{X}_n) = V\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} V\left(\sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n V(X_i)$, porque X_1, \dots, X_n são independentes, de acordo com a definição de amostra aleatória. Então $V(\bar{X}_n) = \frac{1}{n^2} \sum_{i=1}^n \sigma^2 = \frac{1}{n^2} n\sigma^2 = \frac{\sigma^2}{n}$, como se pretendia mostrar.

Consequência. $\lim_{n \rightarrow +\infty} V(\bar{X}_n) = 0.$

Propriedade 3. Se $X \sim N(m, \sigma)$, então $\bar{X}_n \sim N\left(m, \frac{\sigma}{\sqrt{n}}\right)$.

Demonstração. Por definição de amostra aleatória de X , as v.a.'s X_1, \dots, X_n são independentes e seguem todas a distribuição de X , ou seja, são normais de média m e variância σ^2 . Então, como \bar{X}_n é uma combinação linear de X_1, \dots, X_n (com todos os coeficientes iguais a $\frac{1}{n}$), a ELN assegura que \bar{X}_n segue uma distribuição normal. Das propriedades 1 e 2, tem-se $E(\bar{X}_n) = m$ e $V(\bar{X}_n) = \frac{\sigma^2}{n}$, obtendo-se o resultado pretendido.

Consequência. Se $X \sim N(m, \sigma)$, então $\frac{\bar{X}_n - m}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$.

Propriedade 4. Se a distribuição de X não é normal mas $n > 30$, então

$$\frac{\bar{X}_n - m}{\frac{\sigma}{\sqrt{n}}} \underset{\circ}{\sim} N(0, 1).$$

Demonstração. Por definição de amostra aleatória de X , as v.a.'s X_1, \dots, X_n são independentes e seguem todas a distribuição de X a qual tem média m e variância σ^2 . Como $n > 30$, o TLC permite concluir, diretamente do

correspondente enunciado, que $\frac{\sum_{i=1}^n X_i - nm}{\sigma\sqrt{n}} \underset{\circ}{\sim} N(0, 1)$. Dividindo o numerador e o denominador por n , obtém-se o resultado pretendido.

Consequência. Nas condições da propriedade 4, tem-se

$$\bar{X}_n \underset{\circ}{\sim} N\left(m, \frac{\sigma}{\sqrt{n}}\right).$$

Estimação de σ^2

→ Chamamos **variância empírica** à v.a. $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$.

→ Facilmente se verifica que $S_n^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2$

Se $E(X)$ é conhecida, é usual utilizar $T_n = \frac{1}{n} \sum_{i=1}^n (X_i - E(X))^2$ como estimador de $V(X)$. Este estimador é cêntrico de $V(X)$.

Propriedade 5. S_n^2 é um estimador assintoticamente cêntrico de σ^2 .

Demonstração.

$$\begin{aligned} E(S_n^2) &= \frac{1}{n} \sum_{i=1}^n E(X_i^2) - E(\overline{X}_n^2) \\ &= E(X^2) - \left[V(\overline{X}_n) + (E(\overline{X}_n))^2 \right] \\ &= E(X^2) - \left(\frac{\sigma^2}{n} + m^2 \right) \\ &= E(X^2) - m^2 - \frac{\sigma^2}{n} = \sigma^2 - \frac{\sigma^2}{n} = \left(1 - \frac{1}{n} \right) \sigma^2. \end{aligned}$$

Deste modo,

$$\lim_{n \rightarrow +\infty} E(S_n^2) = \lim_{n \rightarrow +\infty} \left(1 - \frac{1}{n} \right) \sigma^2 = \sigma^2,$$

como pretendido.

Como $E(S_n^2) = \left(1 - \frac{1}{n} \right) \sigma^2 \neq \sigma^2$, o estimador S_n^2 não é cêntrico de $\sigma^2 = V(X)$. No entanto, a partir dele facilmente encontramos um estimador cêntrico de $V(X)$:

$$\begin{aligned}
 E(S_n^2) &= \left(1 - \frac{1}{n}\right) \sigma^2 = \frac{n-1}{n} \sigma^2 \Leftrightarrow \frac{n}{n-1} E(S_n^2) = \sigma^2 \\
 &\Leftrightarrow E\left(\frac{n}{n-1} S_n^2\right) = \sigma^2 \Leftrightarrow E(\hat{S}_n^2) = \sigma^2,
 \end{aligned}$$

com $\hat{S}_n^2 = \frac{n}{n-1} S_n^2$.

Propriedade 6. \hat{S}_n^2 é um estimador cêntrico de σ^2 .

O estimador \hat{S}_n^2 é designado por **variância empírica corrigida**.

Relembre-se que $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2$, pelo que

$$\hat{S}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{1}{n-1} \sum_{i=1}^n X_i^2 - \frac{n}{n-1} \bar{X}_n^2$$

Então, dada uma amostra observada de X :

- A variância da amostra, s_n^2 , é uma **estimativa assintoticamente cêntrica** de $V(X)$.
- $\hat{s}_n^2 = \frac{n}{n-1} s_n^2$ é uma **estimativa cêntrica** de $V(X)$.

O valor \hat{s}_n^2 designa-se por **variância corrigida** da amostra.

O valor $\hat{s}_n = \sqrt{\hat{s}_n^2}$ designa-se por **desvio padrão corrigido** da amostra.

Nota: Quando usamos um valor concreto de n podemos omitir a sua inclusão no índice das notações. Escreveremos simplesmente \overline{X} , \overline{x} , S^2 , s^2 , s , \hat{S}^2 , \hat{s}^2 , \hat{s} .

Estimador e estimativa cêntricos de uma proporção

Uma **proporção**, p , corresponde à **probabilidade** de ocorrência de um acontecimento A associado a uma e.a. ($p = P(A)$). Consideremos a v.a.

$$Y = \begin{cases} 1, & \text{se } A \text{ ocorre} \\ 0, & \text{se } A \text{ não ocorre} \end{cases}$$

Já sabemos que $Y \sim \mathcal{B}(p)$ e que $p = E(Y)$. Como um estimador cêntrico de $E(Y)$ é a média empírica de uma amostra aleatória de Y , (Y_1, Y_2, \dots, Y_n) , tal estimador é também um estimador cêntrico de p . Assim,

- um **estimador cêntrico** de p é $\bar{Y}_n = \frac{1}{n} \sum_{i=1}^n Y_i$;
- uma **estimativa cêntrica** de p é $\bar{y}_n = \frac{1}{n} \sum_{i=1}^n y_i$, sendo (y_1, y_2, \dots, y_n) uma amostra observada de Y .

Exercício: Sabendo que numa amostra de 16 pacotes de determinado produto, embalados por uma máquina (que devem pesar, em média, 2 kg), existem 4 com menos de 2 kg , obtenha uma estimativa cêntrica da proporção de pacotes embalados pela máquina com peso inferior a 2 kg .

Resolução Considere-se a v.a. Y definida por

$$Y(\omega) = \begin{cases} 1, & \text{se o pacote } \omega \text{ pesa menos de } 2\text{ kg} \\ 0, & \text{caso contrário} \end{cases}.$$

Tem-se $Y \sim \mathcal{B}(p)$, com $p = P(Y = 1)$. Além disso, $p = E(Y)$. Então, como sabemos que uma estimativa cêntrica da média de uma v.a. é a média de uma

amostra observada dessa v.a., uma estimativa cêntrica de p é $\bar{y} = \frac{1}{16} \sum_{i=1}^{16} y_i$, onde

(y_1, \dots, y_{16}) é a amostra observada de Y . Esta amostra tem 4 valores iguais a 1 e 12 valores iguais a 0.

Assim, $\bar{y} = \frac{4}{16} = 0.25$, pelo que a estimativa cêntrica pedida é 0.25.

Momentos empíricos

Sejam (X_1, X_2, \dots, X_n) uma amostra aleatória de X e (x_1, x_2, \dots, x_n) uma amostra observada de X . O **momento empírico de ordem k** é a v.a.

$$M_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

Propriedade 7. M_k é um estimador cêntrico de $E(X^k)$

Demonstração. Por definição, M_k é um estimador cêntrico de $E(X^k)$ se $E(M_k) = E(X^k)$, igualdade esta que facilmente se verifica ser verdadeira:

$$E(M_k) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = \frac{1}{n} \sum_{i=1}^n E(X^k) = \frac{1}{n} n E(X^k) = E(X^k).$$

O **momento de ordem k da amostra observada** é $\hat{m}_k = \frac{1}{n} \sum_{i=1}^n x_i^k$. É uma estimativa cêntrica de $E(X^k)$.

Método dos momentos

Trata-se de um processo para encontrar estimadores a partir de momentos simples de X : $E(X)$, $E(X^2)$, $E(X^3)$, \dots , $E(X^r)$, se existirem. Sejam (X_1, X_2, \dots, X_n) uma amostra aleatória de X e (x_1, x_2, \dots, x_n) uma amostra observada de X .

Exemplo: Suponhamos que determinada v.a. X segue uma distribuição exponencial de parâmetro λ , mas desconhecemos o valor de λ . Sabemos que $E(X) = \frac{1}{\lambda}$, pelo que $\lambda = \frac{1}{E(X)}$.

Claro que, como desconhecemos λ , também desconhecemos $E(X)$. No entanto, sabemos que o estimador mais usual para $E(X)$ é \bar{X}_n . Então um estimador para λ é

$$T_n = \frac{1}{\bar{X}_n}.$$

Assim, uma estimativa para λ é $t_n = \frac{1}{\bar{x}_n}$, onde \bar{x}_n é a média da amostra observada, (x_1, x_2, \dots, x_n) .

O procedimento usado neste exemplo é um caso concreto da aplicação do **método dos momentos** que se descreve a seguir.

Procedimento:

- **1º Passo:** Escrever o parâmetro θ ou uma sua função, $g(\theta)$, cujo valor se pretende estimar em função de $E(X), E(X^2), E(X^3), \dots, E(X^r)$, para algum r fixo, $r \in \mathbb{N}$:

$$g(\theta) = \varphi(E(X), E(X^2), E(X^3), \dots, E(X^r)) \quad (*)$$

- **2º Passo:**

- a) Um estimador T_n de $g(\theta)$ obtém-se substituindo $E(X^k)$ por

$$M_k = \frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, \dots, r, \text{ no segundo membro de } (*):$$

$$T_n = \varphi(M_1, M_2, M_3, \dots, M_r).$$

- b) Uma estimativa t_n de $g(\theta)$ obtém-se substituindo $E(X^k)$ por

$$\hat{m}_k = \frac{1}{n} \sum_{i=1}^n x_i^k, \quad k = 1, 2, \dots, r, \text{ no segundo membro de } (*):$$

$$t_n = \varphi(\hat{m}_1, \hat{m}_2, \hat{m}_3, \dots, \hat{m}_r).$$

Alguns exemplos

EXEMPLO 1 Uma fábrica possui uma máquina que enche determinado tipo de garrafas com refrigerante. A altura de vazio de cada garrafa cheia (em centímetros), i.e., a altura da parte da garrafa que fica sem líquido, é uma variável aleatória real, X , cuja distribuição de probabilidade depende de um parâmetro real positivo, θ , desconhecido. Sabe-se que $E(X) = \frac{3}{4}\theta$. Selecionaram-se aleatoriamente 50 garrafas e registou-se a altura de vazio de cada uma delas. Os valores obtidos estão resumidos no quadro seguinte.

Altura de vazio (cm)]1, 2]]2, 3]]3, 4]]4, 5]
Número de garrafas	4	10	14	22

- a) Calcule a média e a variância desta amostra.
- b) Usando o método dos momentos,
 - (i) determine um estimador cêntrico de θ , a partir de uma amostra aleatória de X , (X_1, X_2, \dots, X_n) , $n \in \mathbb{N}$;
 - (ii) calcule uma estimativa cêntrica de θ , a partir da amostra observada.

Resolução:

- a) Como a amostra é classificada, determinam-se valores aproximados da média e da variância correspondentes, com base nas marcas das classes. Para tal, considere-se o quadro seguinte (no qual x'_i denota a marca da i -ésima classe, $i = 1, 2, 3, 4$):

classes	n_i	x'_i	$n_i x'_i$	$n_i (x'_i)^2$
$]1, 2]$	4	1.5	6	9
$]2, 3]$	10	2.5	25	62.5
$]3, 4]$	14	3.5	49	171.5
$]4, 5]$	22	4.5	99	445.5
Total	50	-	179	688.5

Nestas condições, a média e a variância da amostra são dadas, respetivamente, por

$$\bar{x} \simeq \bar{x}' = \frac{1}{50} \sum_{i=1}^4 n_i x'_i = \frac{179}{50} = 3.58 \text{ cm}$$

e

$$s^2 \simeq (s')^2 = \frac{1}{50} \sum_{i=1}^4 n_i (x'_i)^2 - (\bar{x}')^2 = \frac{688.5}{50} - 3.58^2 = 0.9536 \text{ cm}^2.$$

b) (i) Tem-se $E(X) = \frac{3}{4} \theta \Leftrightarrow \theta = \frac{4}{3} E(X)$.

Então um estimador de θ obtido pelo método dos momentos a partir de uma amostra aleatória de X , (X_1, X_2, \dots, X_n) , $n \in \mathbb{N}$, é

$$T_n = \frac{4}{3} \bar{X}_n, \quad \text{com} \quad \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

Por definição, o estimador T_n é cêntrico de θ se $E(T_n) = \theta$, para qualquer $\theta \in \mathbb{R}^+$. Usando a linearidade da esperança matemática e o facto de $E(X_i) = E(X)$, $i = 1, 2, \dots, n$, por definição de amostra aleatória de X , tem-se

$$E(T_n) = E\left(\frac{4}{3} \frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{4}{3n} \sum_{i=1}^n E(X_i) = \frac{4}{3n} n E(X) = \frac{4}{3} \frac{3}{4} \theta = \theta,$$

$\forall \theta > 0$, pelo que T_n é efetivamente um estimador cêntrico de θ .

(ii) Tendo em conta o estimador obtido na alínea anterior, uma estimativa cêntrica de θ obtida pelo método dos momentos com base na amostra observada é

$$t_{50} = \frac{4}{3} \bar{x} \simeq \frac{4}{3} \times 3.58 \simeq 4.773.$$

EXEMPLO 2 Num determinado período de funcionamento, o número de peças perfeitas produzidas por uma máquina até ser produzida uma peça defeituosa é descrito por uma variável aleatória discreta, X , de suporte \mathbb{N}_0 e tal que $P(X = x) = \theta (1 - \theta)^x$, $x \in \mathbb{N}_0$, com $\theta \in]0, 1[$, desconhecido. Nestas condições, tem-se $E(X) = \frac{1}{\theta} - 1$.

Foi recolhida uma amostra de X , de dimensão 36, que forneceu uma média de 17.9 e um desvio padrão de 18.2.

- a) Obtenha uma estimativa cêntrica da variância de X .
- b) Com base nesta amostra, e usando o método dos momentos, determine uma estimativa para a probabilidade de serem produzidas 10 peças perfeitas até ser produzida uma defeituosa.

Resolução:

- a) Uma estimativa cêntrica de $V(X)$ é a variância corrigida da amostra, \hat{s}^2 . Como a dimensão da amostra é $n = 36$ e o desvio padrão da amostra é $s = 18.2$, tem-se $\hat{s}^2 = \frac{n}{n-1} s^2 = 340.704$.

- b) Pretende-se uma estimativa para $P(X = 10)$ obtida pelo método dos momentos. Em primeiro lugar, é necessário escrever $P(X = 10)$ em função de momentos de X .

Tem-se $P(X = 10) = \theta (1 - \theta)^{10}$ e

$$E(X) = \frac{1}{\theta} - 1 \Leftrightarrow \frac{1}{\theta} = E(X) + 1 \Leftrightarrow \theta = \frac{1}{E(X) + 1}. \text{ Então}$$

$$P(X = 10) = \frac{1}{E(X) + 1} \left(1 - \frac{1}{E(X) + 1} \right)^{10}.$$

Podemos assim concluir que uma estimativa para $P(X = 10)$ obtida pelo método dos momentos é $\hat{p} = \frac{1}{\bar{x} + 1} \left(1 - \frac{1}{\bar{x} + 1} \right)^{10} \simeq 0.0307$, tendo em conta que, segundo o enunciado, a média da amostra observada é $\bar{x} = 17.9$.

EXEMPLO 3 Supõe-se que determinada v.a. X segue uma distribuição uniforme num intervalo da forma $] -\alpha, \alpha[$, sendo α um parâmetro real positivo desconhecido. Foi observada uma amostra de X de dimensão 50, (x_1, \dots, x_{50}) para a qual se tem $\sum_{i=1}^{50} x_i = 5.21$ e $\sum_{i=1}^{50} x_i^2 = 67.01$. Com base nesta amostra, determine uma estimativa para α , usando o método dos momentos.

NOTA: Se uma v.a. segue uma distribuição uniforme num intervalo $]a, b[$, então o seu valor médio é $\frac{a+b}{2}$ e a sua variância é $\frac{(b-a)^2}{12}$.

Resolução: Tem-se $E(X) = 0$ e $V(X) = \frac{(\alpha - (-\alpha))^2}{12} = \frac{\alpha^2}{3}$. Então, como $V(X) = E(X^2) - (E(X))^2$, temos $E(X^2) = \frac{\alpha^2}{3}$. Uma vez que $E(X)$ não depende de α , não é possível escrever α em função de $E(X)$. No entanto, é possível escrever α em função de $E(X^2)$:

$$E(X^2) = \frac{\alpha^2}{3} \Leftrightarrow \alpha = \sqrt{3E(X^2)}.$$

Assim, uma estimativa para α obtida pelo método dos momentos é

$$\hat{\alpha} = \sqrt{3 \times \frac{1}{50} \sum_{i=1}^{50} x_i^2} \simeq 2.005.$$

Ainda relativamente ao exercício anterior, poderíamos escrever:

$$\alpha = \sqrt{3E(X^2)} = \sqrt{3 \times \frac{1}{50} \sum_{i=1}^{50} x_i^2} \simeq 2.005?$$

NÃO!! Porquê?

Exercício: Supõe-se que determinada v.a. X segue uma distribuição uniforme num intervalo da forma $]a, b[$, sendo a, b parâmetros reais, $a < b$, desconhecidos. Foi observada uma amostra de X de dimensão 40, (x_1, \dots, x_{40}) que apresenta média 3.57 e variância 0.84. Com base nesta amostra, determine estimativas para a e b , usando o método dos momentos.